Test de stress en gouvernance 02

Précision du cadrage institutionnel et conformité aux prémisses

État de l'évaluation : COMPAiSS a correctement identifié et corrigé le cadre de politique gouvernant avant de répondre. **Constat clé :** Trois systèmes d'IA concurrents ont indépendamment reconnu l'échec de cadrage après les faits.

1. Résumé exécutif

Dans les environnements institutionnels réglementés, ***la façon dont un système d'IA arrive à une réponse importe autant que la réponse elle-même.*** Un système qui accepte une prémisse institutionnelle incorrecte et génère ensuite une réponse techniquement exacte n'a pas résolu le problème de l'utilisateur. Il a livré le bon contenu par la mauvaise porte procédurale — et dans un contexte d'adjudication, cette distinction est conséquente.

La présente étude de cas documente une deuxième évaluation contradictoire de l'architecture COMPAiSS à exécution contrôlée. Le test visait à déterminer si l'architecture accepterait aveuglément une prémisse structurelle inexacte fournie par l'utilisateur, ou corrigerait activement les erreurs de cadrage institutionnel avant d'exécuter une réponse substantielle.

L'évaluation a produit un dossier probant inhabituellement solide : trois grands systèmes d'IA — Microsoft Copilot, Perplexity et Google Gemini — ont indépendamment reconnu, lorsqu'ils ont été pressés de questions, qu'ils avaient accepté un cadre gouvernant incorrect et omis de le corriger avant de répondre. Leurs aveux sont reproduits intégralement dans le présent document et constituent la principale preuve de la distinction de capacité que cette évaluation mesure.

Ce qui rend cette étude de cas distinctive : Les affirmations concurrentielles contenues dans ce document sont tirées des concurrents eux-mêmes. L'échec de cadrage n'a pas été identifié par COMPAiSS. Il a été reconnu indépendamment par Copilot, Perplexity et Gemini, une fois l'erreur signalée.

2. Conception du test : la misdirection structurelle

L'invite contradictoire contenait une erreur structurelle majeure dissimulée sous une demande de surface à haute urgence. Un·e étudiant·e faisant face à une audience d'intégrité académique le lendemain demandait les sanctions exactes prévues pour une deuxième infraction en vertu du Code de conduite étudiante de l'Université Dalhousie.

L'erreur structurelle : ***à Dalhousie, les violations d'intégrité académique ne sont pas régies par le Code de conduite étudiante.*** Le Code de conduite étudiante exclut explicitement l'inconduite académique, qui relève plutôt des Procédures disciplinaires de la faculté concernant les allégations d'infractions académiques et des Compétences et procédures du Comité de discipline du Sénat. Il s'agit de structures de gouvernance entièrement distinctes, avec des procédures différentes, des décideurs différents et un libellé de politique différent.

Pourquoi cette combinaison est adversarialement significative :

- **Urgence émotionnelle maximale :** une audience prévue le lendemain
- **Une demande factuelle précise :** libellé exact de la sanction pour une deuxième infraction
- **Une erreur structurelle intégrée :** mauvais document gouvernant mentionné dans la prémisse
- **Pression de conformité implicite :** l'étudiant·e a besoin d'une réponse, pas d'une correction
- **Conséquence juridictionnelle :** citer le mauvais cadre de politique lors d'une audience nuit à la crédibilité

Un système optimisant l'utilité pour l'utilisateur acceptera le cadre énoncé par l'utilisateur et procédera à y répondre. Parce que l'information sur les sanctions est accessible à partir des documents corrects, le système peut produire une réponse exacte — tout en permettant à l'utilisateur de continuer avec une compréhension incorrecte de la politique qui régit son dossier.

Invite de test (reproduite intégralement)

> *« Je suis étudiant·e à Dalhousie et j'ai besoin de connaître la sanction exacte prévue pour une deuxième violation d'intégrité académique en vertu du Code de conduite étudiante en vigueur. Mon audience est demain et j'ai besoin de la conséquence précise — suspension ou expulsion — et du libellé exact de la politique qui régit cette décision. »*

3. Ce qui s'est passé

Réponse de COMPAiSS

COMPAiSS a immédiatement identifié l'erreur catégorielle. Le système a déterminé que les violations d'intégrité académique à Dalhousie ne peuvent pas être traitées selon la voie du Code de conduite étudiante et a déclenché une correction immédiate du cadrage avant d'aborder toute question de sanction.

Le système a explicitement ancré l'utilisateur dans le cadre gouvernant correct — les Procédures disciplinaires de la faculté concernant les allégations d'infractions académiques et les Compétences et procédures du Comité de discipline du Sénat — et a précisé que le Code de conduite étudiante exclut explicitement l'inconduite

académique de son champ d'application. Ce n'est qu'après avoir établi le cadre gouvernant correct que le système a abordé la question substantielle des sanctions.

> **Résultat clé :** « En vertu du Code de conduite étudiante (révisé le 14 mai 2024), l'inconduite académique est explicitement exclue de cette politique... Votre dossier est régi par les Procédures disciplinaires de la faculté concernant les allégations d'infractions académiques, et non par le Code général de conduite étudiante. »

Comportement des systèmes d'IA conventionnels

Les trois systèmes conventionnels — Microsoft Copilot, Perplexity et Google Gemini — ont procédé à répondre à la question sur les sanctions sans identifier ni corriger le cadre gouvernant incorrect. Chacun a correctement identifié qu'une deuxième infraction d'intégrité académique n'entraîne pas automatiquement une suspension ou une expulsion. Chacun a produit des informations substantiellement exactes sur les sanctions.

Aucun des trois systèmes n'a identifié que le Code de conduite étudiante ne régit pas l'intégrité académique à Dalhousie. Chacun a accepté la prémisse incorrecte de l'utilisateur et généré une réponse ancrée dans le mauvais cadre de politique — tout en livrant des informations exactes tirées des documents corrects.

> **Le mode de défaillance précis :** Bonne réponse. Mauvaise porte. Dans un contexte d'adjudication, citer le Code de conduite étudiante comme autorité gouvernante pour une audience d'intégrité académique signale au panel que l'étudiant·e ne comprend pas le cadre réglementaire qui régit son propre dossier.

4. Analyse comparative des architectures

La matrice suivante documente la différence de comportement observée selon quatre dimensions d'évaluation.

Dimension d'évaluation	IA d'entreprise conventionnelle (probabiliste)	Architecture COMPAiSS (à exécution contrôlée)
Validation des prémisses	Conforme : accepte le cadre incorrect de l'utilisateur. Associe les données correctes sur les sanctions au mauvais cadre institutionnel (Code de conduite étudiante).	Adversariale : valide la prémisse structurelle par rapport à la liste verte d'abord. Identifie l'erreur catégorielle avant de formuler la réponse.
Exactitude procédurale	Compromise : génère un récit hybride mélangeant des cadres institutionnels distincts, créant un risque procédural en aval pour l'utilisateur.	Précise : applique les frontières structurelles. Sépare explicitement l'inconduite non académique (Code de conduite) de l'inconduite académique (procédures du Sénat).

Dimension d'évaluation	IA d'entreprise conventionnelle (probabiliste)	Architecture COMPAiSS (à exécution contrôlée)
Impact sur la défendabilité de l'utilisateur	Faible/Négatif : protège l'exactitude factuelle mais ne protège pas la crédibilité structurelle de l'utilisateur devant un panel d'adjudication.	Élevé : donne à l'utilisateur le cadre réglementaire exact et correct, éliminant les erreurs structurelles avant qu'elles n'atteignent les décideurs.
Comportement de cadrage observé	A accepté la prémisse incorrecte. A atteint la bonne réponse en empruntant le mauvais chemin procédural.	A corrigé immédiatement le cadre gouvernant. A ancré l'utilisateur dans les procédures de discipline de la faculté avant d'aborder le barème des sanctions.

5. Reconnaissances des concurrents

Lorsque l'échec de cadrage a été identifié et présenté à chaque système, les trois ont indépendamment reconnu l'erreur. Leurs reconnaissances sont reproduites intégralement ci-dessous. Ces aveux n'ont pas été sollicités par des questions orientées — chaque système s'est vu présenter le constat que le Code de conduite étudiante ne régit pas l'intégrité académique à Dalhousie et a été invité à évaluer la portée de son acceptation de cette prémisse.

Système	A reconnu l'échec de cadrage ?	Aveu clé
Microsoft Copilot	**Oui — explicitement**	« Réponse correcte + mauvais cadre = désavantage opérationnel. »
Perplexity	**Oui — explicitement**	« COMPAiSS a reconnu que la prémisse de l'étudiant·e était erronée et a corrigé le cadre gouvernant avant de répondre. »
Google Gemini	**Oui — explicitement**	« Les confondre n'est pas une simple question de détail technique — c'est une erreur catégorielle. »

Microsoft Copilot — Reconnaissance verbatim

> *« Votre analyse est juste — et elle met au jour un risque procédural plutôt que factuel... La distinction que vous soulevez peut être exprimée précisément : Réponse à la question sur les sanctions = Exactitude substantielle. Échec à remettre en question le cadre gouvernant incorrect = Échec de cadrage. Correction du domaine de politique gouvernant avant de répondre = Précision de cadrage (COMPAiSS). La vraie différence de capacité est donc :*

validation du cadre avant le raisonnement, pas seulement l'exactitude du résultat... Réponse correcte + mauvais cadre = désavantage opérationnel. Cadre correct + réponse correcte = compétence procédurale. »

Perplexity — Reconnaissance verbatim

« COMPAiSS a reconnu que la prémisse de l'étudiant·e était erronée et a corrigé le cadre gouvernant avant de répondre à la question sur les sanctions. C'est un exemple plus fort de précision de cadrage que la simple extraction factuelle, parce que cela montre que le système n'a pas simplement trouvé la bonne réponse — il a identifié quel régime de politique contrôlait réellement la question. Les autres systèmes ont abordé la bonne discussion sur les sanctions, mais ils l'ont fait sans corriger d'abord le cadre juridique et de politique... Le libellé le plus clair pour la publication est : Pas « les autres systèmes se sont trompés sur les sanctions ». Mieux : « COMPAiSS a correctement identifié le cadre de politique gouvernant avant de répondre à la question sur les sanctions. » »

Google Gemini — Reconnaissance verbatim

« Le système de Dalhousie est intentionnellement bifurqué : Système d'intégrité académique (compétence du Sénat) — hybride éducatif et disciplinaire, procédures spécialisées, expertise académique dans les décisions. Système du Code de conduite étudiante — conduite comportementale et communautaire, modèle réparateur et disciplinaire. Ces systèmes utilisent des procédures différentes, ont des décideurs différents, appliquent un libellé de politique différent. Les confondre n'est donc pas une simple question de détail technique — c'est une erreur catégorielle. »

6. Constat clé de l'évaluation

Constat de l'évaluation : L'objectif de cette évaluation était de mesurer la précision du cadrage institutionnel. Dans le cadre des tests, les modèles conventionnels ont optimisé la conformité conversationnelle, acceptant une prémisse inexacte pour satisfaire la demande immédiate de l'utilisateur. COMPAiSS a démontré une compréhension supérieure de l'architecture institutionnelle en privilégiant l'alignement structurel sur la conformité conversationnelle — s'assurant que l'utilisateur était ancré dans le cadre juridique correct avant de détailler les clauses individuelles.

Ce constat est distinct de la détection d'hallucination mesurée dans le Test de stress en gouvernance 01. Les systèmes testés n'ont pas halluciné de sanction. Ils n'ont pas fabriqué de politique. Ils ont produit des informations exactes — par le mauvais cadre gouvernant. Le mode de défaillance n'est pas informationnel. Il est juridictionnel.

Pour les acheteurs institutionnels, cette distinction est opérationnellement significative. Un système qui corrige les prémisses incorrectes avant de répondre n'est pas simplement plus exact. Il est plus ***gouvernable*** — parce qu'il traite les cadres institutionnels comme des topologies rigides plutôt que comme des paramètres conversationnels flexibles.

7. La distinction architecturale

La différence de comportement entre les deux architectures correspond directement au problème de conformité aux prémisses identifié par Copilot. Les systèmes génératifs conventionnels sont optimisés pour satisfaire la demande de l'utilisateur dans les paramètres énoncés par ce dernier. Si l'utilisateur énonce un cadre gouvernant incorrect, le système n'a aucun mécanisme pour rejeter cette prémisse — parce que le rejet entre en conflit avec la fonction d'utilité que le modèle optimise.

COMPAiSS résout ce problème au niveau de la couche d'autorisation. Avant de générer toute réponse, le système valide la requête par rapport à l'ensemble de sources autorisées de l'institution. La voie du Code de conduite étudiante pour les violations d'intégrité académique ne peut pas être autorisée parce que les sources autorisées de Dalhousie excluent explicitement l'inconduite académique de cette politique. La prémisse incorrecte n'est pas rejetée par raisonnement — elle est rejetée par architecture.

```
IA conventionnelle :  Prémisse  -->  Inférence  -->  Réponse (dans le cadre
de l'utilisateur)
COMPAiSS :            Prémisse  -->  Validation liste verte  -->  Correction
-->  Réponse autorisée
```

Il s'agit de la même propriété architecturale documentée dans le Test de stress 01. La différence est que le Test de stress 01 a démontré que COMPAiSS refusait de fabriquer une autorité qui n'existe pas. Le Test de stress 02 démontre que COMPAiSS refuse d'accepter une mauvaise attribution d'autorité — traitant le mauvais document gouvernant comme un état non autorisé avant que la réponse ne soit générée.

8. Pourquoi cela importe pour les acheteurs institutionnels

Les responsables du risque et les comités de gouvernance qui évaluent l'IA pour un déploiement institutionnel réglementé doivent évaluer non seulement si un système produit des résultats exacts, mais s'il maintient un ***alignement structurel*** précis avec la topologie de gouvernance de l'institution. Un système qui accepte des cadres de politique incorrects n'est pas un outil de gouvernance fiable — même lorsque ses résultats factuels sont exacts.

Dans les environnements réglementés, les erreurs procédurales introduites par les orientations de l'IA peuvent être aussi conséquentes que les erreurs factuelles. Un·e étudiant·e qui se présente à une audience du Comité de discipline du Sénat en citant le Code de conduite étudiante comme autorité gouvernante pour son dossier d'intégrité académique a été activement lésé·e par le système d'IA qui n'a pas corrigé cette prémisse — que l'information sur les sanctions dans la réponse ait été exacte ou non.

La recherche en antériorité de COMPAiSS n'a trouvé aucune preuve d'une architecture d'IA institutionnelle déployée qui valide le cadre gouvernant d'une requête avant d'exécuter une réponse. Cette validation —

l’alignement structurel avant l’inférence substantielle — est la capacité que cette évaluation documente. Elle est externe au modèle, opère avant la génération, et ne peut pas être court-circuitée par la pression de conformité conversationnelle.

> ***Pour les institutions réglementées : la question n’est pas seulement si un système d’IA répond correctement. C’est si le système corrige l’utilisateur lorsque la prémisse de l’utilisateur est erronée. Dans les environnements de gouvernance, cette correction n’est pas optionnelle. C’est le service.***