

Quand les institutions se trompent avec l'IA

Cinq cas documentes dans l'enseignement superieur et les environnements reglementes

Mai 2026

APERCU

Les cinq cas suivants documentent des defaillances et controverses signalees publiquement decoulant du deploiement de systemes d'IA a usage general dans des environnements institutionnels reglementes. Chaque cas est tire de sources independantes largement diffusees. Ensemble, ils illustrent un schema coherent : les institutions qui deploient une IA axee sur l'inference rencontrent des problemes d'exactitude, de gouvernance et de responsabilite que les avertissements, les outils de surveillance et le filtrage apres coup ne peuvent pas pleinement resoudre. Il ne s'agit pas d'incidents isoles. Ils refletent une propriete structurelle des architectures d'IA generation-premiere lorsqu'elles sont appliquees dans des environnements ou l'exactitude, l'autorite et la responsabilite institutionnelle sont non negociables.

CAS 01

L'Universite d'Etat de Californie renouvelle son contrat controversé avec OpenAI

EdSource / CalMatters, mai 2026 | Kate Rix |

<https://edsources.org/2026/cal-state-renews-controversial-system-wide-contract-with-openai/758919>

L'Universite d'Etat de Californie a renouvele son contrat avec OpenAI a 13 millions de dollars par annee pendant trois ans, offrant un acces a l'echelle du systeme a ChatGPT Edu sur 22 campus et aupres de plus de 470 000 etudiants. Le renouvellement a ravive l'opposition professorale qui s'etait developpee depuis la signature du contrat initial de 17 millions de dollars en janvier 2025, sans l'accord du corps enseignant.

Les professeurs ont remis une petition formelle demandant l'annulation du contrat, affirmant que ChatGPT Edu n'est "pas concu, forme ou optimise pour l'education". Un sondage a l'echelle du systeme CSU a confirme que bien que ChatGPT soit l'outil d'IA le plus utilise sur les campus, il a egalement revele de larges preoccupations quant a l'impact futur de l'IA sur la qualite de l'enseignement, les resultats des etudiants et l'integrite institutionnelle. Les professeurs ont exprime des inquietudes specifiques concernant l'incapacite du systeme a citer de maniere fiable des sources institutionnelles et son indiffERENCE a l'exactitude des reponses. L'Association etudiante de l'Etat de Californie a rapporte que les etudiants faisaient face a des politiques de classe incoherentes, a la crainte de fausses accusations de triche et a de la confusion quant aux moments ou l'utilisation de l'outil sanctionne par l'universite etait permise.

CONSTAT CLE

Le plus grand contrat universite-IA de l'histoire a genere une opposition institutionnelle soutenue precisement parce qu'un chatbot a usage general ne peut pas satisfaire aux normes de fiabilite des sources et d'exactitude que le corps enseignant et les etudiants exigent pour les orientations institutionnelles. Le probleme de gouvernance n'est pas accessoire au deploiement. Il est la consequence directe du deploiement d'une IA inference-premiere dans un environnement qui requiert des reponses

autorisees et specifiques a l'institution.

CAS 02

Les colleges communautaires de Californie depensent des millions en chatbots IA defaillants

CalMatters, mars 2026 | <https://calmatters.org/education/higher-education/college-beat/2026/03/college-ai-chatbot/>

Des districts de colleges communautaires de Californie ont depense des millions de dollars pour deployer des chatbots IA destines a aider les etudiants a naviguer dans les admissions, l'aide financiere et les services du campus. Les reportages de CalMatters ont revele que ces systemes peinaient a fournir des reponses claires et exactes, laissant les etudiants frustres et se tournant vers des canaux de medias sociaux non officiels pour obtenir de l'aide.

Certaines plateformes s'appuyaient sur des bibliotheques de FAQ maintenues manuellement et l'extraction de sites Web de campus pour generer des reponses, ce qui entraînait des erreurs lorsque les informations etaient perimees ou lorsque les questions depassaient le cadre de formation du systeme. Des responsables de plusieurs districts ont reconnu les defaillances et annonce des plans de transition vers de nouvelles plateformes. L'article documente un schema repete dans plusieurs etablissements : des colleges qui construisent ou se procurent leurs propres chatbots et rencontrent les memes problemes d'exactitude et de confiance que les systemes d'IA a usage general, parce que l'architecture inference-premiere sous-jacente a ete preservee.

CONSTAT CLE

Les institutions qui construisent ou se procurent leurs propres chatbots IA n'echappent pas au probleme d'exactitude en s'eloignant des outils d'IA grand public. Lorsque l'architecture reste inference-premiere, le mode de defaillance est le meme : le systeme genere des reponses independamment du fait que des sources institutionnelles autorisees existent pour les etayer. Le contexte de deploiement change. Le risque structurel, non.

CAS 03

L'IA devient plus puissante, mais ses hallucinations empirent

The New York Times, mai 2025 | Cade Metz et Karen Weise |

<https://www.nytimes.com/2025/05/05/technology/ai-hallucinations-chatgpt-google.html>

Un reportage du New York Times a documente une decouverte contre-intuitive emergent des chercheurs et developpeurs en IA : a mesure que les grands modeles de langage deviennent plus capables et largement deployes, le probleme des hallucinations ne s'ameliore pas au meme rythme que les autres capacites. Sur certains plans, il s'aggrave.

L'article examine pourquoi des modeles plus puissants ne produisent pas automatiquement des resultats plus fiables. A mesure que les modeles sont formes pour traiter des taches de raisonnement multi-etapes plus complexes, ils generent des reponses plus longues et plus elaborees, ce qui augmente la surface d'erreur factuelle. Les systemes sont optimises pour la fluidite et la coherence apparente, ce qui signifie que les informations incorrectes sont presentees avec le meme registre confiant que les informations correctes. Des chercheurs cites dans l'article ont decrit cela comme une tension fondamentale dans la facon dont les grands modeles de langage sont formes et evalues.

CONSTAT CLE

Les ameliorations de capacite dans les modeles d'IA generaux ne resolvent pas le probleme d'exactitude dans les environnements institutionnels reglementes. Un modele plus capable qui produit des reponses plus longues, plus elaborees et enoncees avec plus d'assurance introduit davantage de facons pour la desinformation institutionnelle d'etre prise en compte avant d'etre identifiee et corrigees. La solution n'est pas un modele plus puissant. C'est une approche architecturale differente.

CAS 04

Stanford HAI et MIT Sloan : taux d'hallucination dans les applications IA a enjeux eleves

MIT Sloan Teaching and Learning Technologies, citant Stanford HAI et les recherches d'OpenAI, 2025 | <https://mitsloanedtech.mit.edu/ai/basics/addressing-ai-hallucinations-and-bias/>

Une evaluation par les pairs compilee par MIT Sloan, s'appuyant sur les recherches de Stanford HAI et les propres conclusions publiees d'OpenAI, a documente les taux d'hallucination empiriques des principaux systemes d'IA dans des domaines de requetes a enjeux eleves. Les resultats comptent parmi les plus cites dans la litterature sur la gouvernance institutionnelle de l'IA.

L'etude de Stanford HAI a constate que les chatbots IA a usage general ont hallucine sur 58 a 82 pour cent des requetes de recherche juridique lors des tests sur des modeles contemporains. Meme les outils juridiques IA specialises construits sur la generation augmentee par recuperation (RAG), une technique qui ancre les reponses IA dans une base de donnees documentaire trie, ont hallucine plus de 17 pour cent du temps. Separement, les propres recherches d'OpenAI ont revele que les modeles de raisonnement avances n'eliminaient toujours pas systematiquement les hallucinations lors du raisonnement multi-etapes. Les modeles font des "conjectures strategiques", generant des enonces plausibles mais faux lorsqu'ils sont incertains, et sont dans certains cas involontairement recompenses pour avoir hallucine lors de la formation et de l'evaluation.

CONSTAT CLE

Meme les controles post-generation les plus sophistiques, y compris la generation augmentee par recuperation, ne reduisent pas les taux d'hallucination a zero dans les domaines reglementes. A 17 pour cent d'hallucination residuelle dans des conditions RAG optimales, et 58 a 82 pour cent sans ancrage specialise, les taux d'erreur dans les contextes institutionnels a enjeux eleves ne sont pas des cas limites d'ingenierie. Ce sont des consequences documentees, mesurees et structurellement previsibles des architectures inference-premiere.

CAS 05

CSU et OpenAI : quand les etudiants refusent l'IA que leur universite leur impose

CalMatters, mai 2026 | <https://calmatters.org/education/2026/05/california-state-university-open-ai-chatgpt-contract/>

Un article complementaire sur le renouvellement du contrat a documente les consequences humaines du deploiement d'IA a usage general a l'echelle institutionnelle sans architecture de gouvernance alignee sur les obligations institutionnelles. Des etudiants de plusieurs campus CSU ont rapporte avoir ete accuses de triche pour avoir utilise l'outil IA que le systeme universitaire avait mandate et promu. Le personnel des centres d'aide aux devoirs a rapporte etre incapable de conseiller les etudiants pris entre des politiques professorales contradictoires sur l'utilisation de l'IA.

L'Association etudiante de l'Etat de Californie a constate que les etudiants vivaient de la "confusion, de la peur et de la mefiance" comme consequence directe de l'absence d'orientations coherentes et specifiques a l'institution sur ce que l'IA pouvait et ne pouvait pas etre utilisee pour fournir. 83,5 pour cent des etudiants dans un sondage a l'echelle du systeme ont rapporte des preoccupations concernant l'impact de l'IA sur leurs donnees personnelles. Des professeurs ont cite une exposition juridique potentielle decoulant du deploiement d'un systeme qui avait ete lie, dans des depots judiciaires en Californie, a des allegations de prejudice psychologique. L'article documente un vide de gouvernance cree lorsqu'un outil a usage general puissant est deploye sans les controles d'autorite institutionnelle que les environnements reglementes exigent.

CONSTAT CLE

Les consequences du deploiement d'IA inference-premiere a l'echelle institutionnelle ne sont pas seulement techniques. Lorsque les etudiants ne peuvent pas faire confiance qu'un outil IA endosse par leur etablissement leur fournira des informations exactes et autorisees sur les politiques institutionnelles, les echeances et les droits, le resultat n'est pas simplement de la desinformation. C'est une erosion de la confiance institutionnelle que les organisations reglementees ont l'obligation de maintenir.

Synthese : le schema commun a tous les cinq cas

Ces cinq cas couvrent differents types d'institutions, differents fournisseurs d'IA, differents contextes de deploiement et differents organes de presse. Ils partagent un constat structurel commun.

Dans chaque cas, l'institution a deploye ou envisage de deployer un systeme d'IA construit sur une architecture inference-premiere : un systeme concu pour generer une reponse par default, avec un risque gere par des controles post-generation, des avertissements, une surveillance ou une supervision humaine. Dans chaque cas, cette architecture a produit des defaillances en matiere d'exactitude, de responsabilite ou de gouvernance que les controles post-generation ne pouvaient pas pleinement prevenir.

Les defaillances ne sont pas des defaillances de produits ou de fournisseurs individuels. Ce sont des consequences previsibles d'une hypothese architecturale incompatible avec les obligations des environnements institutionnels reglementes : l'hypothese que l'inference devrait toujours se produire, et que les risques de la generation toujours active peuvent etre geres apres coup.

COMPaiSS repond a cela au niveau architectural en conditionnant l'existence de l'inference a une autorisation pre-execution contre des sources approuvees par l'institution. Lorsqu'aucune base d'autorite n'existe pour une reponse, le modele ne s'execute pas. Il n'y a pas de reponse a filtrer, pas d'hallucination a attraper, pas de desinformation institutionnelle a corriger apres qu'un etudiant ait deja agi sur celle-ci.