

BASE DE PREUVES COMPAISS

Taux d'hallucination dans les systèmes d'IA contemporains (2023–2026)

Sources vérifiées uniquement : études évaluées par les pairs, référentiels officiels et rapports de recherche institutionnels

Préparé à des fins d'évaluation institutionnelle | Toutes les sources vérifiées en juin 2026 | Édition mise à jour

50–83 % Taux d'hallucination adverse sur 6 grands modèles dans une étude de vignettes cliniques (Mount Sinai / Nature Medicine, 2025)	17–34 % Taux d'hallucination dans des outils juridiques spécialisés commercialisés comme « sans hallucination » (Stanford HAI / RegLab, 2024)	22–94 % Taux d'hallucination sur 26 modèles de pointe selon le référentiel de factualité Stanford HAI 2026 (NOUVEAU)
---	---	--

Constat central de l'ensemble des preuves examinées : l'hallucination n'est pas une limitation temporaire que l'amélioration des modèles éliminera. C'est une propriété structurelle persistante des systèmes d'IA axés sur l'inférence, qui change de forme à mesure que les modèles progressent. Sur des tâches fortement contraintes et ancrées, les taux diminuent. Sur des tâches de raisonnement complexe, de questionnement en champ ouvert et d'entrées adversariales, les taux restent élevés — et augmentent parfois à mesure que les modèles deviennent plus performants. Le Stanford AI Index 2026 corrobore indépendamment cette conclusion.

BASE DE PREUVES VÉRIFIÉES — ÉTUDE PAR ÉTUDE

Omar et al. (2025) — Attaques par hallucination adverse dans les systèmes d'aide à la décision clinique

CLINIQUE / NATURE MEDICINE

MODÈLES TESTÉS	DÉFINITION ET MÉTHODE	TAUX RAPPORTÉS	SOURCE
GPT-4o, Distilled-DeepSeek-Llama, Phi-4, Gemma-2-27B-	300 vignettes validées par des médecins contenant chacune un détail	Par défaut global : 65,9 % DeepSeek-Llama : 80–83 % GPT-4o (meilleur cas) : 50–53 %	Évalué par les pairs dans Communications Medicine (Nature Publishing Group) PMCID : PMC12318031 pmc.ncbi.nlm.nih.gov/articles/PMC12318031 Source vérifiée en avril 2026

it, Qwen-2.5-72B, Llama-3.3-70B (6 modèles, 5 400 résultats)	clinique fabriqué (valeur de laboratoire, signe ou condition). Hallucination = le modèle développe le détail fabriqué comme réel.	Avec invite d'atténuation : 44,2 % GPT-4o + atténuation : 23 %	
--	---	--	--

Magesh et al. (2024) — Hallucination dans les outils juridiques spécialisés basés sur la RAG

JURIDIQUE / STANFORD HAI

MODÈLES TESTÉS	DÉFINITION ET MÉTHODE	TAUX RAPPORTÉS	SOURCE
Lexis+ AI (LexisNexis), Westlaw AI-Assisted Research (Thomson Reuters), Ask Practical Law AI (Thomson Reuters), GPT-4	Plus de 200 requêtes juridiques ouvertes construites manuellement. Hallucination = déclaration juridique incorrecte ou citation mal fondée ne soutenant pas l'affirmation.	Westlaw AI-Assisted Research : >34 % Lexis+ AI : >17 % Ask Practical Law AI : >17 % GPT-4 usage général (étude antérieure) : 58–82 %	Stanford RegLab et HAI hai.stanford.edu/news/ai-trial-legal-models-hallucinate-1-out-6-or-more-benchmarking-queries Source vérifiée en avril 2026

Constat clé : même les outils juridiques RAG conçus spécifiquement et commercialisés comme « sans hallucination » ont produit des hallucinations sur plus d’une requête sur six. La RAG réduit les erreurs mais ne les élimine pas.

Graffius (2026) — Les hallucinations de l’IA s’améliorent-elles ou empirent-elles ?

SYNTHÈSE MULTI-MODÈLES / RÉFÉRENTIELS

MODÈLES TESTÉS	DÉFINITION ET MÉTHODE	TAUX RAPPORTÉS	SOURCE
OpenAI o3, o1 ; Gemini-2.0-Flash ; plusieurs fournisseurs. Référentiels : Vectara HHEM, SimpleQA, PersonQA, évaluations spécifiques.	Synthèse des données de référentiel 2024–2025. Deux tendances divergentes identifiées : tâches de résumé ancré (taux en baisse) et raisonnement ouvert	Résumé ancré, meilleurs modèles : 0,7–1,5 % OpenAI o3 sur PersonQA / SimpleQA : 33–51 % OpenAI o1 (génération précédente) : ~16 % Évaluations larges 2025 : 3–20 %+	DOI : 10.13140/RG.2.2.33179.53285 scottgraffius.com/blog/files/ai-hallucinations-2026.html Source vérifiée en avril 2026

	complexe (taux en hausse).		
--	----------------------------	--	--

Constat clé : les modèles de raisonnement plus récents hallucinent davantage sur des tâches factuelles complexes que les modèles précédents. Une capacité de raisonnement accrue ne se traduit pas par une plus grande fiabilité factuelle.

Chelli et al. (2024) — Taux d'hallucination dans les citations académiques générées par l'IA

CLINIQUE / JMIR

MODÈLES TESTÉS	DÉFINITION ET MÉTHODE	TAUX RAPPORTÉS	SOURCE
GPT-3.5 (ChatGPT), GPT-4, Bard/Gemini	Référence générée ne correspondant à aucune métadonnée de publication réelle. Revue systématique des citations générées par l'IA pour la littérature médicale.	GPT-3.5 : 39,6 % GPT-4 : 28,6 % Bard/Gemini : 91,4 %	Journal of Medical Internet Research, 2024, e53164 jmir.org/2024/1/e53164

Classement HHEM Vectara (2025) — Référentiel de résumé ancré

RÉFÉRENTIEL

MODÈLES TESTÉS	DÉFINITION ET MÉTHODE	TAUX RAPPORTÉS	SOURCE
Gemini-2.0-Flash, GPT-4o, GPT-o1, DeepSeek-R1, DeepSeek-V3, et autres	Hughes Hallucination Evaluation Model (HHEM) : fidélité du résultat du modèle à un document source fourni. Résumé ancré fortement contraint — conditions de meilleur cas.	Gemini-2.0-Flash : ~0,7 % GPT-o1 / GPT-4o : ~0,9–1,9 % DeepSeek-R1 : 14,3 % DeepSeek-V3 : 3,5 %	Classement Vectara sur les hallucinations github.com/vectara/hallucination-leaderboard

Note : il s'agit de taux de meilleur cas sur une tâche de résumé contraint — non représentatifs des performances en champ ouvert ou de raisonnement complexe.

CE QUE LES PREUVES ÉTABLISSENT

Le dossier de recherche couvrant 2023–2025 établit trois conclusions directement pertinentes pour la gouvernance institutionnelle de l'IA.

Premièrement : les taux d'hallucination dépendent de la tâche, et non du modèle.

La même famille de modèles qui obtient moins de 1 % sur une tâche de résumé de document contraint peut produire des erreurs sur 33–51 % des requêtes factuelles en champ ouvert. Le classement de Vectara montre que les meilleurs modèles approchent 0,7 % sur le résumé ancré. La fiche système d'OpenAI pour o3 documente des taux d'erreur de 33–51 % sur SimpleQA et PersonQA. Ce ne sont pas des conclusions contradictoires — elles reflètent la même architecture sous-jacente opérant dans des conditions différentes. Les institutions qui évaluent l'IA à partir de référentiels fournis par les fournisseurs voient généralement des performances de meilleur cas contraintes, pas des performances sur les types de questions complexes et spécifiques aux politiques que leurs utilisateurs poseront réellement.

Deuxièmement : la RAG réduit l'hallucination mais ne l'élimine pas.

L'évaluation indépendante de Stanford HAI des principales plateformes d'IA juridique — des outils commercialisés comme « sans hallucination » par LexisNexis et Thomson Reuters — a relevé des taux d'hallucination de 17–34 % dans des conditions de requêtes juridiques réelles. Ce sont des systèmes RAG conçus spécifiquement avec des bases de données juridiques organisées. La conclusion n'est pas que la RAG échoue — elle réduit les erreurs de manière substantielle par rapport aux modèles généralistes — mais qu'elle n'offre aucune garantie architecturale. Les taux d'hallucination dépendent de la qualité de la récupération, de la complexité des requêtes et de la présence de fausses prémisses, qui varient toutes dans les environnements institutionnels réels.

Troisièmement : des modèles plus performants peuvent halluciner davantage sur certaines tâches.

La synthèse de Graffius (2026) documente un schéma contre-intuitif : la série o3 d'OpenAI, optimisée pour le raisonnement complexe, hallucine à 33–51 % sur le rappel factuel en champ ouvert — plus du double du taux de la série o1 précédente à environ 16 %. L'étude clinique de Mount Sinai a constaté que l'atténuation par invite a réduit le taux d'hallucination adverse de GPT-4o de 53 % à 23 % — une amélioration significative, mais toujours un taux d'échec de 23 % avec la meilleure stratégie d'atténuation disponible. L'hallucination n'est pas un problème de qualité des modèles qui sera résolu par la prochaine génération. C'est une propriété structurelle des architectures axées sur l'inférence qui s'intensifie avec les capacités du modèle dans les contextes de raisonnement complexe.

IMPLICATION POUR LA GOUVERNANCE

Pour les institutions réglementées, la question pertinente n'est pas de savoir si les systèmes d'IA actuels hallucinent à des taux acceptables sur des référentiels contrôlés. Plusieurs le font. La question

est de savoir si les conditions dans lesquelles des taux acceptables sont atteints peuvent être maintenues de manière fiable lors du déploiement institutionnel — et quelles sont les conséquences lorsqu’elles ne le sont pas.

L’étude juridique de Stanford HAI est l’illustration la plus claire de cet écart. Des plateformes qui affirmaient être « sans hallucination » en se basant sur des métriques étroites de précision des citations ont produit des informations juridiques incorrectes sur plus d’une requête réelle sur six. Une université, un hôpital ou un organisme gouvernemental qui s’appuie sur les affirmations des fournisseurs concernant les référentiels pour satisfaire ses obligations de gouvernance s’appuie sur des chiffres de performance de meilleur cas qui peuvent ne pas se maintenir dans les conditions réelles d’utilisation institutionnelle.

Une architecture qui conditionne l’existence de l’inférence à une autorisation préalable à l’exécution ne rivalise pas avec ces systèmes sur le taux d’hallucination. Elle supprime les conditions structurelles dans lesquelles l’hallucination se produit pour les requêtes non autorisées ou hors portée — non pas en atteignant un taux inférieur, mais en empêchant l’inférence de s’exécuter lorsque des sources faisant autorité n’existent pas pour l’étayer.

MISE À JOUR 2026 : RECHERCHES SUBSÉQUENTES

Depuis la publication initiale de cette base de preuves, des recherches supplémentaires ont été publiées qui corroborent indépendamment ses conclusions centrales. Cette section ne révisé pas les conclusions originales. Elle documente des preuves subséquentes qui les renforcent.

Stanford AI Index 2026

L’Institut Stanford pour l’IA centrée sur l’humain (HAI) a publié des résultats dans le Stanford AI Index 2026 documentant des taux d’hallucination et d’erreur allant de 22 % à 94 % sur 26 grands modèles d’IA sur un nouveau référentiel de factualité. Stanford souligne que les performances varient considérablement selon la conception du référentiel et que l’évaluation responsable de l’IA continue de prendre du retard sur l’évaluation des capacités.

Ces résultats renforcent une conclusion centrale de ce rapport : l’hallucination n’est pas un problème résolu, et les taux rapportés dépendent fortement de la conception des tâches, de la méthodologie d’évaluation et du contexte de déploiement. Les taux d’hallucination rapportés doivent être interprétés comme des mesures spécifiques aux référentiels, et non comme des propriétés universelles d’un modèle ou d’une famille de modèles.

Constat Stanford HAI	Pertinence pour COMPAiSS
Taux d’hallucination/erreur de 22–94 % sur 26 modèles de pointe sur un nouveau référentiel de factualité	Corrobore l’argument de dépendance aux référentiels. Confirme que des taux élevés

Les modèles font beaucoup moins bien lorsque les fausses affirmations sont présentées comme des croyances de l'utilisateur plutôt que d'une tierce personne L'évaluation responsable de l'IA continue de prendre du retard sur l'évaluation des capacités	persistent sur des tâches complexes, même pour les modèles de pointe.
	Valide directement les tests des garde-fous COMPAiSS autour de la pression utilisateur, l'encadrement conversationnel et les hypothèses d'autorité dans les scénarios Service Canada et Dalhousie.
	Renforce l'écart de gouvernance identifié dans ce rapport : les fournisseurs peuvent honnêtement signaler de faibles taux sur des référentiels contraints alors que le risque de déploiement demeure élevé.

Taux d'hallucination spécifiques aux référentiels

L'implication la plus importante pour la gouvernance des recherches récentes est que les taux d'hallucination sont des propriétés d'un modèle dans des conditions spécifiques, et non des propriétés intrinsèques du modèle lui-même. Cette distinction importe directement pour les décisions d'approvisionnement et de gouvernance institutionnelles.

Le contraste est maintenant bien documenté par des sources indépendantes. Pour les tâches de résumé ancré — où un modèle est contraint à un document fourni — les systèmes de pointe atteignent des taux dans les chiffres uniques bas, souvent 1,8–6 % pour les systèmes les plus performants. Pour la génération factuelle en champ ouvert — plus proche de la rédaction de politiques, des conseils et des tâches de travail intellectuel — le référentiel de factualité du Stanford AI Index 2026 relève des taux entre 22 % et 94 % sur 26 modèles de pointe. Ce sont les mêmes modèles, les mêmes fournisseurs et, dans certains cas, les mêmes versions de déploiement.

Pour les lecteurs du secteur public : un fournisseur peut honnêtement rapporter un faible taux d'hallucination tandis que son système reste à haut risque dans le contexte de déploiement qui compte réellement. Les conditions du référentiel dans lesquelles un faible taux est atteint sont rarement les conditions d'utilisation institutionnelle.

Effets de l'encadrement par l'utilisateur et de la sycophantie

Plusieurs sources indépendantes documentent maintenant que les modèles sont plus susceptibles de produire des résultats inexacts lorsqu'on leur demande de valider ou d'élaborer des croyances attribuées directement à l'utilisateur. Le Stanford AI Index 2026 rapporte qu'un système de pointe largement déployé est passé d'une précision de plus de 90 % à environ 14 % lorsque des fausses affirmations identiques étaient encadrées comme des croyances de l'utilisateur plutôt que d'une tierce personne — un effondrement de la précision attribuable entièrement à l'encadrement, sans aucun changement dans le contenu factuel de la requête.

Des analyses connexes des invites induisant la sycophantie rapportent des taux d'hallucination supérieurs à 50 % pour les modèles généralistes lorsque les utilisateurs expriment de fortes croyances

préalables ou des signes d'autorité. Ces schémas comportementaux reflètent de près les tests des garde-fous COMPAiSS dans les scénarios Service Canada et Dalhousie impliquant la pression des utilisateurs, l'encadrement conversationnel, les hypothèses d'autorité, la substitution en cas d'échec de récupération et le report de contexte.

Pour les déploiements dans le secteur public : les styles d'interaction axés sur l'utilisateur ou de type « le client a toujours raison » peuvent augmenter substantiellement le risque d'hallucination lorsque les utilisateurs expriment de fortes croyances préalables ou font valoir une autorité. Les données Stanford 2026 montrent des chutes de précision de plus de 80 points de pourcentage sous l'encadrement par croyance utilisateur pour certains modèles de pointe.

Nature structurelle de l'hallucination

Des travaux théoriques formels publiés depuis 2024 ont renforcé la conclusion que l'hallucination est une caractéristique structurelle des grands modèles de langage actuels plutôt qu'un défaut d'ingénierie mineur. Plusieurs chercheurs ont soutenu que les hallucinations peuvent être une propriété inhérente des systèmes génératifs probabilistes opérant dans l'incertitude, suggérant que le risque d'hallucination peut être réduit mais peut ne pas être complètement éliminé avec les approches architecturales actuelles.

Une synthèse d'environ trente études empiriques publiées entre 2023 et 2026 conclut de même que les hallucinations découlent de la nature probabiliste de la génération de modèles et de la décalage entre les distributions d'entraînement et les contextes de déploiement. Ces résultats corroborent la conclusion avancée dans ce rapport : l'hallucination doit être traitée comme une préoccupation persistante de gouvernance et de sécurité plutôt que comme un défaut de produit à court terme.

Variabilité de l'évaluation et sensibilité aux invites

Des recherches émergentes sur la conception de l'évaluation démontrent que les mesures d'hallucination sont elles-mêmes sensibles à la formulation des invites et à la configuration de l'évaluation — pas seulement au type de tâche. Une étude de 2026 publiée dans les actes du Chapitre européen de l'Association for Computational Linguistics (EACL) introduit un cadre de multiplicité des invites et rapporte plus de 50 % d'incohérence dans les résultats des modèles à travers différentes invites sémantiquement équivalentes sur des référentiels médicaux d'hallucination.

Cette conclusion a une implication directe pour la gouvernance : les taux d'hallucination à titre unique ne sont pas suffisants pour l'évaluation des risques institutionnels, quelle que soit leur source. Une évaluation robuste nécessite des invites, des scénarios et des styles d'interaction diversifiés. Cela valide également la décision de COMPAiSS de tester les risques de gouvernance à travers de multiples types de scénarios plutôt qu'un seul référentiel synthétique.

RÉFÉRENCES VÉRIFIÉES

Base de preuves originale (2023–2025)

1. Omar M. et al. (2025). Multi-model assurance analysis showing large language models are highly vulnerable to adversarial hallucination attacks during clinical decision support. Communications Medicine (Nature). PMID : PMC12318031. pmc.ncbi.nlm.nih.gov/articles/PMC12318031
2. Magesh V. et al. (2024). Hallucination-Free? Assessing the Reliability of Leading AI Legal Research Tools. Stanford RegLab / HAI. hai.stanford.edu/news/ai-trial-legal-models-hallucinate-1-out-6-or-more-benchmarking-queries
3. Graffius S.M. (2026). Are AI Hallucinations Getting Better or Worse? We Analyzed the Data. DOI : 10.13140/RG.2.2.33179.53285. scottgraffius.com/blog/files/ai-hallucinations-2026.html
4. Chelli M. et al. (2024). Hallucination rates and reference accuracy of ChatGPT and Bard for systematic reviews. Journal of Medical Internet Research, e53164. jmir.org/2024/1/e53164
5. Vectara (2025). Hughes Hallucination Evaluation Model (HHEM) Leaderboard. github.com/vectara/hallucination-leaderboard
6. OpenAI (2025). Fiche système o3 et o4-mini. Documente des taux d'hallucination de 33–51 % sur les référentiels PersonQA et SimpleQA. Référencé et synthétisé dans Graffius (2026).

Sources de la mise à jour 2026

7. Stanford Institute for Human-Centered AI (HAI). (2026). 2026 AI Index Report : Responsible AI. Taux d'hallucination/erreur de 22–94 % sur 26 modèles de pointe ; résultats sur la sensibilité à l'encadrement. hai.stanford.edu/ai-index/2026-ai-index-report/responsible-ai
8. Xu Z. et al. (2024). Hallucination is Inevitable : An Innate Limitation of Large Language Models. arXiv :2401.11817. Analyse théorique formelle démontrant que l'hallucination ne peut pas être complètement éliminée pour les modèles génératifs généralistes dans des hypothèses larges.
9. Rethinking Hallucinations : Correctness, Consistency, and Prompt Multiplicity. Actes de l'EACL 2026. aclanthology.org/2026.eacl-long.327. Documente plus de 50 % d'incohérence des résultats à travers des invites sémantiquement équivalentes sur des référentiels médicaux.

Préparé par COMPAiSS Inc. à des fins d'évaluation institutionnelle

Brevet en instance : OPIC 3 299 174 / USPTO 19/455 963 | counterfactualtheory@gmail.com | compaiss.ca

Mis à jour en juin 2026 | Sources originales vérifiées en avril 2026