Hallucinations par conception

Une evaluation intermodeles de la maniere dont les grands cabinets de conseil en IA conseillent leurs clients pour gerer les erreurs de l'IA generative

APERCU METHODOLOGIQUE

Le present rapport de synthese a ete elabore au moyen d'une analyse comparative en plusieurs etapes utilisant quatre grands modeles de langage independants - GPT, Perplexity, Copilot et Gemini - auxquels a ete fourni un prompt identique et strictement circonscrit, portant exclusivement sur la maniere dont les grandes organisations conceptualisent et controlent les hallucinations de l'IA. Chaque modele a produit une evaluation autonome de Deloitte, PwC, KPMG et Microsoft, fondee uniquement sur la documentation publique relative aux produits, aux cadres de gouvernance et aux descriptions architecturales. Ces quatre rapports ont ensuite ete traites comme des intrants analytiques independants et examines cote a cote afin d'identifier les zones de concordance complete, d'alignement partiel et de divergence significative. Les conclusions finales presentees ici n'introduisent aucune nouvelle interpretation ni synthese au-dela de ce qui est etaye par les resultats des quatre modeles; elles refletent plutot une evaluation de consensus intermodeles qui pondere les constats en fonction de leur coherence et de leur recurrence dans l'ensemble des analyses.

APPROCHES DE RECHERCHE PROPRES A CHAQUE MODELE (RESUME)

Bien que les quatre modeles aient repondu au meme prompt et aux memes contraintes de portee, chacun a employe une approche distincte de recherche et d'extraction. Ces differences sont resumees ci-dessous afin d'assurer la transparence quant a la maniere dont les evaluations sous-jacentes ont ete produites.

GPT

GPT a mene une analyse structuree fondee sur des documents, ancree dans des documents publics des firmes, y compris des cadres de gouvernance de l'IA, de la documentation sur l'IA responsable, des descriptions de produits et des explications architecturales. L'analyse visait a extraire les hypotheses explicites et implicites relatives aux hallucinations, a les cartographier aux points de controle du cycle de vie (avant, pendant ou apres la generation) et a classifier le paradigme architectural implicite. GPT n'a pas eu recours a la recherche Web en temps reel lors de la phase finale de synthese; il a plutot traite les documents cites dans les rapports fournis comme faisant autorite et a strictement limite ses conclusions a ce que ces documents permettaient d'etayer.

Copilot

Copilot a applique une methodologie de synthese interrapports plutot que d'introduire une expansion independante des sources. Il a traite les evaluations des firmes generees par les quatre modeles comme des intrants analytiques fixes et a procede a une normalisation a l'aide d'une taxonomie commune (cadre de definition des hallucinations, inevitabilite ou evitabilite, point de controle du cycle de vie et paradigme architectural). Copilot a mis l'accent sur une ponderation du consensus fondee sur les preuves, en distinguant explicitement les niveaux d'accord fort, modere et mixte, et a evite de resoudre les desaccords par l'interpretation. Aucun nouveau fait ni aucune inference architecturale n'ont ete introduits au-dela de ce qui figurait deja dans les rapports eux-memes.

Perplexity

Perplexity a combine une recherche Web ciblee et une extraction fondee sur des documents. Il a lance des requetes ciblees sur les sites Web des firmes, des livres blancs, des blogues techniques et, dans le cas de Microsoft, de la documentation de plateforme, portant specifiquement sur les hallucinations, l'ancrage, le RAG et les controles d'IA responsable. Il a ensuite recoupe ces constats avec le rapport compile fourni afin d'en assurer l'alignement. Lors de la phase de consensus, Perplexity a traite le document compile comme une source de verite et a restreint la synthese aux points explicitement presents dans les analyses des quatre modeles, en signalant les niveaux de consensus selon la recurrence plutot que l'emphase.

Gemini

Gemini a adopte une approche medico-legale axee sur la mise a l'epreuve d'hypotheses, visant a identifier les hypotheses architecturales sous-jacentes plutot que les affirmations de gouvernance de surface. Il a analyse les cadres des firmes, la documentation des plateformes et, pour Microsoft, les descriptions des outils techniques afin de determiner le moment ou l'intervention se produit par rapport a l'execution du modele. Gemini a explicitement verifie si une organisation demontrait un refus d'execution avant generation ou un blocage strict de l'inference et a signale des constats negatifs lorsqu'aucune preuve de ce type n'apparaissait. Lors de l'etape intermodeles, Gemini a mis l'accent sur l'alignement des interpretations des modeles afin de garantir que les conclusions refletent une comprehension collective plutot qu'une lecture propre a un seul modele.

SYNTHESES FINALES DE LA RECHERCHE DE CHAQUE MODELE D'IA

ChatGPT - Synthese de l'evaluation des quatre firmes

POSITION GENERALE	GPT conclut de facon constante que les quatre firmes fonctionnent selon un paradigme de generation d'abord, avec attenuation a posteriori. Les hallucinations sont traitees comme des proprietes inherentes et probabilistes des LLM et sont gerees au moyen de la gouvernance, du RAG et de la supervision humaine apres l'inference.
Deloitte	Les hallucinations sont presentees comme des defaillances de fiabilite et des risques lies aux modeles; elles sont inevitables et regies apres la generation par l'assurance qualite, la gouvernance et la revision.
PwC	Les hallucinations sont decrites comme des sorties plausibles mais non fondees; elles sont attenuees par le RAG et la discipline des prompts pendant et apres la generation, sans etre structurellement empechees.
KPMG	Les hallucinations sont traitees comme des risques endemiques de fiabilite; elles sont abordees principalement par la gouvernance, l'auditabilite et la surveillance apres la generation.
Microsoft	Les hallucinations sont presentees comme du 'contenu non ancre'; elles sont attenuees par l'ancrage, des boucles de correction et la gouvernance apres l'inference.
CONSTAT CLE	**GPT ne releve aucune preuve de refus d'execution avant l'inference ni de prevention structurelle chez aucune des firmes.**

GEMINI - Synthese de l'evaluation des quatre firmes

POSITION GENERALE	Gemini s'aligne etroitement sur GPT, en mettant l'accent sur les hallucinations comme des artefacts inevitables de modeles probabilistes, geres par des controles en couches apres la generation.
Deloitte	Les hallucinations correspondent a un risque de fiabilite des sorties; elles sont inevitables et controlees apres la generation par la gouvernance et la revision humaine.
PwC	Les hallucinations sont presentees comme un decalage entre la probabilite et la realite; elles sont traitees au moyen de 'membranes', du RAG et de la revision, mais la generation a toujours lieu.
KPMG	Les hallucinations sont traitees comme un risque persistant; elles sont regies au moyen de cadres de gestion des risques traditionnels apres la generation.
Microsoft	Les hallucinations sont formalisees comme un manque d'ancrage; elles sont reduites par l'ancrage et la correction, sans etre eliminers.
CONSTAT CLE	**Gemini affirme explicitement qu'aucune des quatre firmes ne remet en question l'hypothese de la generation d'abord.**

COPILOT - Synthese de l'evaluation des quatre firmes

POSITION GENERALE	Copilot caracterise les quatre organisations comme supposant que les hallucinations sont attendues et inevitables, et que leur attenuation est principalement axee sur les etapes pendant et surtout apres la generation.
Deloitte	Les hallucinations constituent des risques operationnels et de gouvernance; elles sont gerees apres la generation par la validation et la supervision.
PwC	Les hallucinations representent des risques inherents a l'IA generative; elles sont attenuees par les prompts, le RAG et la gouvernance de l'IA responsable.
KPMG	Les hallucinations sont integrees aux preoccupations de fiabilite et de confiance; elles sont traitees par des controles et des audits post-generation.
Microsoft	Les hallucinations sont considerees comme des defaillances d'ancrage; elles sont attenuees par des outils de plateforme (RAG, correction, couches de securite).
CONSTAT CLE	**Copilot ne releve aucune defense du blocage avant la generation; le refus est traite comme un comportement configurable, et non comme une architecture par defaut.**

PERPLEXITY - Synthese de l'evaluation des quatre firmes	
POSITION GENERALE	Perplexity fournit le niveau de detail le plus granulaire sur le cycle de vie, mais parvient a la meme conclusion : les hallucinations sont structurellement inevitables et sont attenuees par des controles compensatoires superposes a des systemes axes sur la generation d'abord.
Deloitte	Les hallucinations sont des defaillances de fiabilite statistiquement attendues; elles sont attenuees par le RAG, l'assurance qualite et la gouvernance apres la generation.
PwC	Les hallucinations sont des risques inherents a l'IA generative; elles sont reduites par des techniques de prompting, des 'doubles verifications' par RAG et la revision.
KPMG	Les hallucinations sont presentees comme des risques endemiques de fiabilite; elles sont gerees par la gouvernance, la validation et la surveillance apres la generation.
Microsoft	Les hallucinations sont definies comme des sorties non ancrees; elles sont abordees par l'ancrage, la detection et la correction apres l'inference initiale.
CONSTAT CLE	**Perplexity souligne explicitement que le RAG est traite comme un mecanisme compensatoire, et non comme une barriere stricte empechant l'inference.**

OBSERVATION METAMODELE INTERMODELES

Derivee des quatre syntheses : les quatre modeles d'IA s'entendent independamment sur les points suivants :

- Les hallucinations sont traitees comme inevitables par les quatre firmes.
- L'inference se produit par defaut.
- L'attenuation intervient pendant et surtout apres la generation.
- Aucune firme n'est decrite comme imposant un refus d'execution structurel avant l'inference.

Prepare par COMPAiSS Inc. aux fins d'evaluation institutionnelle. Brevet en instance : OPIC 3 299 174 / USPTO 19/455 963 | frank.harvey@compaiss.ca | compaiss.ca